

잠재공간에서의 이상형 추정

일반 Gaussian prior와 Maximum-Variance Line Query

Problem Statement 및 알고리즘 정리

KAIST

2026년 8월

문제


사용자는 잠재공간에 고정된 선호점 z^* 를 가진다. 학습자는 매 라운드마다 M 개의 이미지를 보여주고, 사용자의 선택만 관찰하여 z^* 를 추정한다.

제안 아이디어

현재 posterior가 가장 길게 퍼진 방향을 찾고, 그 방향 위에 M 개의 잠재 쿼리를 균등 간격으로 배치한다.

가장 불확실한 방향을 질문 $\Rightarrow$ 그 방향의 uncertainty 감소 $\Rightarrow \hat{z}_T \approx z^*$.

전체 상호작용 흐름



역할 분리

z^* 는 고정된 실제 값이고, $p_t(z)$ 는 그 값을 모르는 학습자의 믿음이다.


잠재공간과 이미지

- Encoder $E : \mathcal{X} \rightarrow \mathcal{Z}$ 는 이미지를 잠재벡터로 바꾼다.
- Decoder $D : \mathcal{Z} \rightarrow \mathcal{X}$ 는 잠재벡터를 이미지로 바꾼다.
- 알고리즘은 잠재공간에서 쿼리를 설계하고, 사용자는 이미지를 본다.

이론적 단순화

$$E(D(z)) \approx z.$$

생성된 이미지를 다시 encoding했을 때 원래 쿼리점과 가깝다고 가정한다.



기호	의미
$z^* \in \mathcal{Z} \subseteq \mathbb{R}^d$	사용자의 고정된 실제 선호점
$p_0(z) = \mathcal{N}(\mu_0, \Sigma_0)$	interaction 전 초기 prior
H_t	t 라운드 이전까지의 쿼리와 선택 기록
$p_t(z) = p(z \mid H_t)$	현재 posterior
$\hat{z}_t = \arg \max_z p_t(z)$	현재 MAP 추정치
$\Sigma_t = \text{Cov}(Z \mid H_t)$	현재 posterior covariance
λ_t, v_t	Σ_t 의 최대 고유값과 대응 단위 고유벡터
$\hat{z}_t^{(1)}, \dots, \hat{z}_t^{(M)}$	t 라운드의 M 개 잠재 쿼리점
$x_t^{(m)} = D(\hat{z}_t^{(m)})$	사용자에게 제시되는 m 번째 이미지
$Y_t \in \{1, \dots, M\}$	사용자가 선택한 이미지 번호

초기 prior와 실제 선호점

초기 믿음

interaction 전에 학습자는

$$Z \sim p_0(z) = \mathcal{N}(\mu_0, \Sigma_0)$$

라는 믿음을 가진다.

- μ_0 : 새 사용자에게 대한 초기 중심 추정
- Σ_0 : 어떤 방향을 얼마나 불확실하게 보는지 나타내는 행렬
- 실제 사용자의 z^* 는 한 번 정해진 뒤 interaction 동안 고정

중요한 구분

prior와 posterior가 분포라고 해서 사용자의 선호가 매번 변하는 것은 아니다. 분포는 고정된 z^* 에 대한 학습자의 불확실성이다.

사용자 선택 모델

라운드 t 에서 잠재 쿼리 집합을

$$Q_t = \{\hat{z}_t^{(1)}, \dots, \hat{z}_t^{(M)}\}$$

라고 하자. 사용자는 z^* 에 가까운 이미지를 더 높은 확률로 선택한다.

Multinomial softmax choice

$$\mathbb{P}(Y_t = m \mid z^*, Q_t) = \frac{\exp\left[-\frac{1}{2} \left\| \hat{z}_t^{(m)} - z^* \right\|_2^2\right]}{\sum_{j=1}^M \exp\left[-\frac{1}{2} \left\| \hat{z}_t^{(j)} - z^* \right\|_2^2\right]}.$$

- 가장 가까운 이미지가 가장 높은 선택확률을 가진다.
- 선택은 확률적이므로, 한 번의 응답이 틀릴 수도 있다.

Bayes posterior update

사용자가 $Y_t = y_t$ 를 선택하면

$$p_{t+1}(z) = \frac{\mathbb{P}(Y_t = y_t \mid z, Q_t)p_t(z)}{\int_{\mathcal{Z}} \mathbb{P}(Y_t = y_t \mid \tilde{z}, Q_t)p_t(\tilde{z}) d\tilde{z}}.$$

선택과 잘 맞는 영역

Likelihood가 크므로 posterior 질량이 증가한다.

선택과 잘 맞지 않는 영역

Likelihood가 작으므로 posterior 질량이 감소한다.

장점

선택되지 않은 영역을 완전히 삭제하지 않으므로, 한 번의 noisy response로 정답을 영구히 잃지 않는다.

Estimator와 학습 목표

현재 추정치는 posterior의 MAP으로 둔다.

$$\hat{z}_t = \arg \max_{z \in \mathcal{Z}} p_t(z).$$

최종 목표는

$$\hat{z}_T \approx z^*$$

가 되게 하는 것이다.

평가값

$$\mathcal{E}_T = \|\hat{z}_T - z^*\|_2^2.$$


왜 Σ_0^{-1} -norm이 아닌가?

Σ_0 는 초기 belief의 모양을 나타낸다. 본 설정에서는 latent geometry 자체의 오차를 보고자 하므로 기본 평가는 Euclidean distance를 사용한다. 필요하면 표준화 오차를 보조지표로 추가할 수 있다.

왜 posterior에서 무작위로만 뽑지 않는가?


무작위 posterior sample

posterior 중심 근처에 여러 점이 우연히 몰릴 수 있다.



의도적인 line query

가장 불확실한 방향을 따라 점들을 벌려 놓는다.



목표


단순 sampling이 아니라, 현재 가장 필요한 방향의 정보를 의도적으로 얻는다.

Step 1: 최대 분산 방향 선택

현재 posterior covariance의 최대 고유쌍을 계산한다.

$$\Sigma_t v_t = \lambda_t v_t, \quad \lambda_t = \lambda_{\max}(\Sigma_t), \quad \|v_t\|_2 = 1.$$

- λ_t : 현재 가장 큰 directional variance
- v_t : 그 variance가 나타나는 방향
- 이 방향이 현재 가장 잘 모르는 방향이다.



Step 2: M 개의 균등 간격 쿼리

먼저 $[-1, 1]$ 위의 균등 간격 계수를 정의한다.

$$b_m = -1 + \frac{2(m-1)}{M-1}, \quad m = 1, \dots, M.$$

초기 prior가 주는 자연스러운 고정 반지름을

$$r_0 = \sqrt{\lambda_{\max}(\Sigma_0)}$$

로 둔다. 그러면


$$\hat{z}_t^{(m)} = \hat{z}_t + r_0 b_m v_t$$

이다.

해석

첫 라운드의 가장 불확실한 방향에서 prior 표준편차 한 단위씩 좌우로 펼친 폭을 모든 라운드에서 기준 쿼리 폭으로 사용한다. 별도의 수동 temperature나 scale parameter가 필요하지 않다.

잠재 쿼리가 이미지가 되는 과정



$$x_t^{(m)} = D\left(\hat{z}_t^{(m)}\right).$$

다차원 질문이 1차원 비교가 되는 이유

모든 쿼리는 v_t 방향의 한 직선 위에 있다.

$$\hat{z}_t^{(m)} = \hat{z}_t + r_0 b_m v_t.$$

$s_t = v_t^\top (z^\star - \hat{z}_t)$ 라고 두면

$$\left\| \hat{z}_t^{(m)} - z^\star \right\|_2^2 = (r_0 b_m - s_t)^2 + C_t,$$

여기서 C_t 는 모든 m 에 공통이다.



핵심

공통항 C_t 는 softmax의 분자와 분모에서 사라진다. 따라서 이번 응답은

“실제 선호가 v_t 방향으로 어디에 있는가?”

라는 1차원 질문이 된다.

선택 후 posterior는 어떻게 변하는가?



효과

posterior는 선택된 방향으로 이동하고, v_t 방향의 uncertainty는 줄어든다.

Maximum-Variance Line Query 알고리즘

❶ 초기화: $p_0(z) = \mathcal{N}(\mu_0, \Sigma_0)$, $\hat{z}_0 = \mu_0$.

❷ 현재 MAP과 covariance를 계산한다.

$$\hat{z}_t = \arg \max_z p_t(z), \quad \Sigma_t = \text{Cov}(Z \mid H_t).$$

❸ 최대 분산 방향 v_t 를 구한다.

$$\Sigma_t v_t = \lambda_{\max}(\Sigma_t) v_t.$$

❹ M 개의 잠재 쿼리를 만든다.

$$\hat{z}_t^{(m)} = \hat{z}_t + r_0 b_m v_t.$$

❺ $x_t^{(m)} = D(\hat{z}_t^{(m)})$ 를 보여주고 선택 Y_t 를 관측한다.

❻ $p_{t+1}(z) \propto \mathbb{P}(Y_t \mid z, Q_t) p_t(z)$ 로 업데이트한다.

이론적 직관: 한 라운드의 정보 방향

한 라운드의 Fisher information은 다음 rank-one 형태를 가진다.

$$\mathcal{I}_t(z^\star) = \gamma_t v_t v_t^\top,$$

$$\gamma_t = \text{Var}(r_0 b_{Y_t} \mid z^\star, Q_t).$$

- 이번 라운드는 v_t 방향에만 직접적인 정보를 준다.
- 후보가 서로 구분되고 선택확률이 완전히 포화되지 않으면 $\gamma_t > 0$ 이다.
- 알고리즘은 매번 가장 큰 posterior variance 방향을 선택한다.

따라서

현재 가장 큰 uncertainty를 가진 방향의 precision을 우선 증가시키는 greedy experimental design으로 해석할 수 있다.

단순화된 수렴 그림

국소적으로 posterior가 Gaussian에 가깝고, 선택된 방향의 precision이 매번 최소 $\underline{\gamma} > 0$ 만큼 증가한다고 가정하자.

$$\Sigma_{t+1}^{-1} \approx \Sigma_t^{-1} + \gamma_t v_t v_t^\top.$$

고유방향이 안정적인 단순화된 모델에서는 최대 분산 방향을 반복해서 선택하므로

$$\lambda_{\max}(\Sigma_T) \lesssim \frac{1}{\lambda_{\max}(\Sigma_0)^{-1} + \underline{\gamma} \lfloor T/d \rfloor} = O\left(\frac{d}{T}\right).$$

해석

한 라운드는 한 방향을 줄이지만, 항상 가장 큰 방향부터 줄이므로 여러 라운드가 지나면 전체 covariance가 균형 있게 작아진다.

실험에서 확인할 것

- 최종 추정오차

$$\|\hat{z}_T - z^*\|_2, \quad \|\hat{z}_T - z^*\|_2^2.$$

- 라운드별 오차곡선

$$e_t = \|\hat{z}_t - z^*\|_2.$$

- posterior uncertainty

$$\lambda_{\max}(\Sigma_t), \quad \text{tr}(\Sigma_t).$$

- Decoder consistency

$$\left\| E(D(\hat{z}_t^{(m)})) - \hat{z}_t^{(m)} \right\|_2.$$

가장 쉬운 첫 실험

$z^* \sim \mathcal{N}(\mu_0, \Sigma_0)$ 를 한 번 샘플링하고, softmax 사용자를 시뮬레이션하여 MVLQ가 random posterior query보다 더 빠르게 오차를 줄이는지 비교한다.

Problem Statement

고정된 잠재 선호점 z^* 를 M -way stochastic choice를 통해 추정한다. 초기 belief는 일반적인 Gaussian prior $\mathcal{N}(\mu_0, \Sigma_0)$ 이다.

제안 알고리즘

현재 posterior covariance의 최대 고유값 방향을 선택하고, 현재 MAP을 중심으로 그 방향 위에 M 개의 쿼리를 균등 간격으로 놓는다.

핵심 메시지

가장 잘 모르는 방향을 직접 질문한다.

단순하지만, 정보 방향과 posterior 감소를 명확하게 설명할 수 있는 active preference estimation 방법이다.