

잠재공간에서의 이상형 추정 Maximum-Variance Line Query

일반 Gaussian prior 기반 Problem Statement 및 알고리즘

핵심 문제. 사용자는 잠재공간에 고정된 선호점 z^* 를 가진다. 학습자는 매 라운드마다 M 개의 잠재 쿼리를 이미지로 변환해 제시하고, 사용자의 선택만으로 z^* 를 추정한다.

핵심 알고리즘. 현재 posterior covariance가 가장 크게 퍼진 방향을 선택하고, 현재 MAP 추정치를 중심으로 그 방향 위에 M 개의 쿼리를 균등 간격으로 배치한다.

1. Notation과 문제 설정

기호	의미
$z^* \in \mathcal{Z} \subseteq \mathbb{R}^d$	사용자의 고정된 실제 선호점
$p_0(z) = \mathcal{N}(\mu_0, \Sigma_0)$	interaction 전 초기 prior
H_t	t 라운드 이전까지의 쿼리와 선택 기록
$p_t(z) = p(z H_t)$	현재 posterior
$\hat{z}_t = \arg \max_z p_t(z)$	현재 MAP 추정치
$\Sigma_t = \text{Cov}(Z H_t)$	현재 posterior covariance
λ_t, v_t	Σ_t 의 최대 고유값과 대응 단위 고유벡터
$\hat{z}_t^{(1)}, \dots, \hat{z}_t^{(M)}$	t 라운드에 생성하는 M 개의 잠재 쿼리점
$x_t^{(m)} = D(\hat{z}_t^{(m)})$	사용자에게 제시되는 m 번째 이미지
$Y_t \in \{1, \dots, M\}$	사용자가 선택한 이미지 번호

초기에는

$$Z \sim p_0(z) = \mathcal{N}(\mu_0, \Sigma_0)$$

라는 belief를 둔다. 여기서 z^* 는 interaction 동안 변하지 않는 실제 값이고, prior와 posterior는 그 고정된 값을 모르는 학습자의 불확실성을 나타낸다. Gaussian prior이므로 초기 MAP은

$$\hat{z}_0 = \mu_0$$

이다.

이미지 공간과 잠재공간의 변환은

$$E: \mathcal{X} \rightarrow \mathcal{Z}, \quad D: \mathcal{Z} \rightarrow \mathcal{X}$$

로 나타낸다. 이론에서는 $E(D(z)) \approx z$ 라고 이상화하며, 실제 구현에서는 생성된 이미지를 다시 encoding하여 실현된 잠재벡터를 확인할 수 있다.

사용자 선택 모델

라운드 t 의 잠재 쿼리 집합을

$$Q_t = \{\hat{z}_t^{(1)}, \dots, \hat{z}_t^{(M)}\}$$

라고 하자. 사용자는 실제 선호점 z^* 에 가까운 쿼리를 더 높은 확률로 선택한다.

$$\mathbb{P}(Y_t = m | z^*, Q_t) = \frac{\exp\left[-\frac{1}{2} \left\| \hat{z}_t^{(m)} - z^* \right\|_2^2\right]}{\sum_{j=1}^M \exp\left[-\frac{1}{2} \left\| \hat{z}_t^{(j)} - z^* \right\|_2^2\right]}.$$

선택 $Y_t = y_t$ 를 관측하면 posterior는

$$p_{t+1}(z) = \frac{\mathbb{P}(Y_t = y_t | z, Q_t) p_t(z)}{\int_{\mathcal{Z}} \mathbb{P}(Y_t = y_t | \tilde{z}, Q_t) p_t(\tilde{z}) d\tilde{z}}$$

로 갱신된다.

최종 estimator와 평가값은

$$\hat{z}_T = \arg \max_{z \in \mathcal{Z}} p_T(z), \quad \mathcal{E}_T = \left\| \hat{z}_T - z^* \right\|_2^2$$

로 둔다. Σ_0 는 초기 belief의 모양을 나타내며, 반드시 평가 metric의 가중치일 필요는 없다. 본 문서에서는 latent geometry에 대한 Euclidean error를 기본 평가로 사용한다.

2. Maximum-Variance Line Query

2.1 가장 불확실한 방향

현재 posterior covariance의 최대 고유쌍을 계산한다.

$$\Sigma_t v_t = \lambda_t v_t, \quad \lambda_t = \lambda_{\max}(\Sigma_t), \quad \|v_t\|_2 = 1.$$

v_t 는 현재 posterior가 가장 길게 퍼진 방향이며, 따라서 현재 가장 잘 모르는 방향이다.

2.2 M 개의 균등 간격 쿼리

$[-1, 1]$ 위의 균등 간격 계수를

$$b_m = -1 + \frac{2(m-1)}{M-1}, \quad m = 1, \dots, M$$


로 정의한다. 초기 prior로부터 자연스러운 고정 반지름

$$r_0 = \sqrt{\lambda_{\max}(\Sigma_0)}$$

을 정하고, 쿼리를

$$\hat{z}_t^{(m)} = \hat{z}_t + r_0 b_m v_t$$


로 배치한다. 즉, 현재 MAP을 중심으로 최대 분산 방향의 좌우에 M 개의 점을 일정한 간격으로 놓는다. 이 반지름은 초기 prior의 최대 표준편차에서 정해지므로 별도의 수동 scale parameter가 필요하지 않다.



각 잠재 쿼리는 Decoder를 통해 실제 이미지가 된다.

$$x_t^{(m)} = D(\hat{z}_t^{(m)}).$$

따라서 전체 구현 흐름은 다음과 같다.



2.3 전체 알고리즘

1. $p_0(z) = \mathcal{N}(\mu_0, \Sigma_0)$ 로 초기화하고 $r_0 = \sqrt{\lambda_{\max}(\Sigma_0)}$ 를 계산한다.
2. 라운드 t 에서 $\hat{z}_t = \arg \max_z p_t(z)$ 와 $\Sigma_t = \text{Cov}(Z | H_t)$ 를 계산한다.
3. $\Sigma_t v_t = \lambda_{\max}(\Sigma_t) v_t$ 를 만족하는 최대 분산 방향 v_t 를 구한다.
4. $b_m = -1 + 2(m-1)/(M-1)$ 로 두고 $\hat{z}_t^{(m)} = \hat{z}_t + r_0 b_m v_t$ 를 만든다.
5. $x_t^{(m)} = D(\hat{z}_t^{(m)})$ 를 사용자에게 제시하고 선택 Y_t 를 관측한다.
6. $p_{t+1}(z) \propto \mathbb{P}(Y_t | z, Q_t) p_t(z)$ 로 posterior를 갱신한다.
7. T 라운드 후 $\hat{z}_T$ 를 반환한다.

3. 왜 이 쿼리가 정보를 주는가?

모든 쿼리는 v_t 방향의 한 직선 위에 있다. $s_t = v_t^\top (z^* - \hat{z}_t)$ 라고 두면

$$\left\| \hat{z}_t^{(m)} - z^* \right\|_2^2 = (r_0 b_m - s_t)^2 + C_t,$$

여기서 C_t 는 모든 후보에 공통인 항이다. 공통항은 softmax에서 소거되므로, 한 번의 응답은 사실상

“실제 선호가 v_t 방향으로 어디에 있는가?”

라는 1차원 질문이다.

한 라운드의 Fisher information은

$$\mathcal{I}_t(z^*) = \gamma_t v_t v_t^\top, \quad \gamma_t = \text{Var}(r_0 b_{Y_t} \mid z^*, Q_t)$$

의 rank-one 형태를 가진다. 즉, 이번 라운드는 선택한 v_t 방향에 정보를 더한다. 알고리즘은 항상 posterior variance가 가장 큰 방향을 선택하므로, 현재 가장 큰 uncertainty를 우선 줄이는 greedy design으로 볼 수 있다.

단순화된 수렴 그림

국소적으로 posterior가 Gaussian에 가깝고, 선택확률이 포화되지 않아 매 라운드의 정보량이 $\gamma_t \geq \underline{\gamma} > 0$ 로 하계된다고 가정하자. 또한 고유방향이 안정적인 근사 아래에서

$$\Sigma_{t+1}^{-1} \approx \Sigma_t^{-1} + \gamma_t v_t v_t^\top$$

가 된다. 최대 분산 방향을 반복해서 선택하면

$$\lambda_{\max}(\Sigma_T) \lesssim \frac{1}{\lambda_{\max}(\Sigma_0)^{-1} + \underline{\gamma} \lfloor T/d \rfloor} = O\left(\frac{d}{T}\right)$$

형태의 감소를 기대할 수 있다. 이는 exact global theorem이 아니라, 알고리즘의 local Gaussian 분석이다.

4. 평가와 구현 체크

핵심 평가값

$$\|\hat{z}_t - z^*\|_2, \quad \|\hat{z}_t - z^*\|_2^2.$$

보조 분석값

$$\lambda_{\max}(\Sigma_t), \quad \text{tr}(\Sigma_t), \quad \left\| E(D(\hat{z}_t^{(m)})) - \hat{z}_t^{(m)} \right\|_2.$$

가장 쉬운 synthetic experiment에서는 $z^* \sim \mathcal{N}(\mu_0, \Sigma_0)$ 를 한 번 샘플링하고, 명시한 softmax choice model로 사용자의 선택을 시뮬레이션한다. 이후 MVLQ와 random posterior query를 비교하여 라운드별 추정오차와 posterior uncertainty가 얼마나 빠르게 감소하는지 확인한다.

한 줄 요약. 일반 Gaussian prior $\mathcal{N}(\mu_0, \Sigma_0)$ 에서 시작하여, 매 라운드 현재 posterior의 최대 분산 방향을 찾고 그 방향 위에 M 개의 이미지를 균등하게 배치한다. 사용자 선택을 Bayes rule로 누적하면 현재 가장 불확실한 방향부터 순차적으로 줄여 나갈 수 있다.